

ROTEIRO DE APRESENTAÇÃO — Sistema Inteligente de Tradução de Libras

Slide 1 — Abertura Bom dia/boa tarde a todos. Somos Júlia Almeida Leite e Maria Eduarda Mariano Coelho, e hoje vamos apresentar nosso TCC: o Sistema Inteligente de Tradução de Libras, desenvolvido com Visão Computacional e Processamento de Linguagem Natural, sob orientação do professor Thyago Conchado Quintas.

Slide 2 — Os Quatro Eixos (Introdução) Antes de mergulhar no problema, deixa a gente apresentar os quatro pilares que sustentam toda a solução. O sistema é construído sobre: Visão Computacional, para capturar os gestos; Deep Learning, para reconhecê-los; NLP com spaCy, para estruturar as frases; e um LLM, para refinar e garantir fluência natural no português. Esses quatro eixos trabalham em sequência, formando um pipeline completo do gesto à frase.

Slide 3 — O Problema Por que isso importa? Segundo o IBGE, o Brasil tem 10,7 milhões de pessoas com dificuldade permanente de audição. Desses, apenas 284 mil sabem Libras — menos de 3% do total. Isso cria barreiras sérias no acesso à saúde, à educação e ao cotidiano. Intérpretes são escassos, e a comunicação entre surdos e ouvintes ainda é um grande desafio não resolvido.

Slide 4 — Justificativa: A relevância do nosso trabalho tem três dimensões. Academicamente, combinamos três áreas de IA num pipeline único — algo ainda pouco explorado para o Libras. Na prática, reduzimos a dependência de intérpretes em situações do dia a dia. E como avanço, tratamos a Libras como a língua complexa que ela realmente é, traduzindo frases completas, não apenas palavras isoladas.

Slide 5 — Hipótese Nossa hipótese central é: uma arquitetura híbrida de CNN, LSTM e LLM consegue reconhecer e traduzir sinais estáticos e dinâmicos da Libras para o português com acurácia e fluência suficientes para uso em situações reais de comunicação. É isso que buscamos validar.

Slide 6 — Objetivos O objetivo principal é implementar esse sistema de ponta a ponta — da câmera à frase em português. Para chegar lá, traçamos cinco objetivos secundários: levantamento bibliográfico, seleção e pré-processamento de datasets, projeto da arquitetura híbrida, desenvolvimento do protótipo com captura via webcam, e validação com métricas e usuários reais.

Slide 7 — Metodologia da Pesquisa Bibliográfica Para embasar o projeto, realizamos uma revisão bibliográfica sistemática com método de screening. Partimos de 100 artigos, filtramos por título, resumo e texto completo, chegando a 3 trabalhos incluídos na revisão final. Os critérios priorizaram publicações entre 2021 e 2026, em português ou inglês, com metodologia técnica reproduzível e avaliação quantitativa de desempenho.

Slide 8 — Diferenças entre Libras e Português Um ponto essencial: Libras não é português sinalizado. Ela tem ordem frasal flexível — pode ser SVO, SOV, OSV ou VOS — e é construída pela simultaneidade de configurações de mão, movimento, locação, orientação e expressões não manuais. O português, por outro lado, tem ordem fixa SVO e marcadores explícitos como artigos e preposições. Essa diferença estrutural é o coração do desafio de tradução.

Slide 9 — Datasets e Pré-processamento Utilizamos três datasets: o MINDS-Libras, com 20 sinais gravados por 6 pessoas; o V-Libras, com mais de 1.300 termos; e o Libras BSL, focado no alfabeto manual estático. Para lidar com desbalanceamento e escassez de dados, aplicamos Data Augmentation, SMOTE sobre landmarks, ponderação de classes na função de perda e divisão treino/validação/teste.

Slide 10 — Visão Computacional O pipeline de visão começa na câmera. O frame capturado é processado pelo MediaPipe, que extrai os landmarks — e então o sinal é classificado. As três funções centrais são: detecção das mãos, reconhecimento do gesto e extração das características relevantes para classificação.

Slide 11 — MediaPipe O MediaPipe Hands detecta 21 pontos 3D por mão, em dois estágios — primeiro a palma, depois as articulações — de forma invariante a iluminação e tom de pele. Além disso, o Face Mesh captura 468 pontos faciais para identificar as Expressões Não Manuais, como sobrancelhas levantadas para perguntas ou contrações para negações. Essas expressões têm função gramatical em Libras e não podem ser ignoradas.

Slide 12 — Deep Learning Para reconhecimento, usamos dois modelos. A CNN é ideal para sinais estáticos — como o alfabeto manual — aprendendo padrões espaciais hierárquicos da mão. Já a LSTM processa sequências temporais de landmarks, capturando trajetória, velocidade e transições entre poses, sendo a escolha natural para sinais dinâmicos.

Slide 13 — Custo Computacional Um cuidado importante no projeto foi o custo computacional. Em vez de processar pixels brutos de vídeo, trabalhamos com vetores compactos de coordenadas dos landmarks — isso reduz drasticamente a dimensionalidade. Manter o vocabulário inicial limitado a um domínio específico também mantém os modelos leves e treináveis sem hardware especializado.

Slide 15 — Camada Linguística: NLP + LLM Após reconhecer os sinais, o pipeline linguístico entra em ação. O spaCy realiza tokenização e etiquetagem morfofssintática, constrói a árvore de dependência sintática e reorganiza os tokens na ordem SVO do português. Em seguida, o LLM refina a frase, inserindo artigos, preposições e garantindo fluência natural. Por exemplo: [VOCÊ, QUER, ÁGUA] → "Você quer água?"

Slide 16 — Árvores de Dependência As árvores de dependência sintática são o que torna o NLP robusto à ordem flexível da Libras. Elas mapeiam relações gramaticais binárias entre os tokens — sujeito, verbo, objeto — independente de como chegaram. O spaCy implementa isso com um parser baseado em transições, processando da esquerda para a direita com operações SHIFT, LEFT-ARC e RIGHT-ARC.

Slide 17 — Avaliação e Validação Para validar o sistema, planejamos quatro frentes: acurácia e matriz de confusão para o módulo de reconhecimento gestual; métrica BLEU para comparar as traduções geradas com referências humanas; análise de latência para garantir uso em tempo real; e sessões com membros da comunidade surda e intérpretes para avaliação qualitativa.

Slides 19 — Trabalhos Relacionados

Trabalhos Relacionados

Trabalho 2 Interpretação de gestos de Libras usando K-Means e Random Forest



Problema abordado

Barreira de comunicação entre usuários e não usuários da língua de sinais alinhado diretamente com esta pesquisa. Foco em reduzir custo computacional sem perder acurácia.

Resultados

Acurácia de 94,72% sobre o MINDS-Libras. Demonstra que representações mais leves (landmarks + ML clássico) podem ser eficientes com menor complexidade computacional.

Metodologia

MediaPipe para extração de landmarks corporais + agrupamento K-Means + classificação com KNN e Random Forest. Dataset: MINDS-Libras. Abordagem mais leve que deep learning puro.

Limitações

- Foco restrito à classificação de sinais isolados, sem tratamento de construção de frases nem contexto linguístico.
- Desafios comuns: iluminação, ângulo de câmera, aumento de vocabulário.

→ Diferencial do TCC

Avança ao incorporar módulo de NLP responsável por organizar os sinais identificados em frases estruturadas em Português.

Slide 21 — Solução Proposta Em resumo: nossa solução é um pipeline completo — da câmera à frase. MediaPipe captura os landmarks, CNN e LSTM reconhecem os sinais, e NLP + LLM transformam os tokens em português fluente e natural. Tudo em tempo real, via webcam.

Slide 22 — Cronograma O desenvolvimento está organizado em três fases ao longo de 16 semanas. A Fase 1 cobre planejamento e treinamento das redes. A Fase 2, integração do NLP e LLM. A Fase 3, interface, testes finais e ajustes. O trabalho culmina na entrega e apresentação do TCC 2.

Slide 23 — Encerramento Muito obrigada a todos pela atenção. Ficamos à disposição para perguntas.